DEEP DIVE TÉCNICO • COMPONENTES Y TÉCNICAS

Stack Tecnológico del Ecosistema

Desglose exhaustivo de motores, protocolos, técnicas de indexación y recuperación determinista.

01 / CAPA DE TRANSPORTE E INTEROPERABILIDAD

Model Context Protocol (MCP)

Técnicas e Implementación

- Arquitectura cliente-servidor estándar abierta por Anthropic.
- Exposición dinámica de *Tools* y recursos contextuales mediante JSON-RPC.
- Desacoplamiento total entre el cliente (Cursor, Open WebUI) y las fuentes de datos.

Propósito Arquitectónico

Elimina la necesidad de escribir integraciones rígidas o custom APIs para cada LLM.

Permite que múltiples servidores especializados (`study-cybercirujas`, `k8s-docs-mcp`, `rag-tutor`) colaboren de forma simultánea en la misma sesión del agente.

02 / CAPA DE BÚSQUEDA Y RECUPERACIÓN

Hybrid Retrieval + Cross-Encoder Reranking

Fase A

Búsqueda Léxica (BM25)

Recuperación exacta por frecuencias de términos. Crítico para comandos, flags y parámetros técnicos (`apiVersion`).

Fase B

Búsqueda Semántica (Vectores)

Embeddings densos mediante modelos como BGE-M3 para capturar la intención y el contexto conceptual.

Fase C

Cross-Encoder Rerank

Reordenamiento profundo de los resultados combinados para garantizar que la evidencia más precisa esté al tope.

03 / CAPA DE CONOCIMIENTO ESTRUCTURADO

GraphRAG con KùzuDB & OmniGraph

Técnicas Aplicadas

- Modelado ontológico de dependencias técnicas (Nodos y Aristas).
- Base de datos de grafos embebida en memoria (KùzuDB) sin servidores pesados.
- Recorrido de grafos para identificar prerrequisitos de arquitectura.

Propósito Arquitectónico

Resuelve el problema de los fragmentos de texto aislados en RAG tradicionales.

Permite que el tutor entienda cómo se interconectan los componentes de un sistema (ej. cómo un Ingress interactúa con un Service y un Deployment).

04 / CAPA DE INFERENCIA Y SOBERANÍA

Ollama Engine (Qwen2.5:7b / BGE-M3)

Técnicas e Infraestructura

- Ejecución local optimizada (quantization GGUF / GPU acceleration).
- Modelos de lenguaje de código abierto de altas prestaciones (Qwen2.5).
- Generación de embeddings locales desatendida.

Propósito Arquitectónico

Garantiza soberanía absoluta y cero dependencia de APIs de pago o nubes de terceros.

Evita la filtración de código propietario o datos de estudiantes, operando 100% offline o en infraestructura privada.

05 / CAPA DE ACTUALIZACIÓN AUTOMATIZADA

GitHub Actions + Git Sparse-Checkout

Técnicas de Ingesta

- Sincronización programada (Cron / Workflows) contra repositorios upstream.
- Descarga selectiva mediante Git Sparse-Checkout (solo carpetas de interés).
- Indexación incremental por hashes SHA-256 para evitar reprocesos.

Propósito Arquitectónico

Mantiene el conocimiento siempre fresco ante la evolución constante de las tecnologías cloud native.

Permite ”regenerar en lugar de reentrenar”, automatizando la actualización de la base de datos documental sin intervención manual.

Mapa de Componentes y Técnicas

Capa	Tecnología	Técnica Principal
Transporte	`MCP Protocol`	JSON-RPC Tool Exposition
Búsqueda	`Hybrid & Rerank`	BM25 + Dense Vectors + Cross-Encoder
Grafo	`KùzuDB / GraphRAG`	Ontological Node-Edge Traversal
Inferencia	`Ollama / Qwen2.5`	Local Quantization (GGUF) + GPU
Sincronización	`GitHub Actions`	Sparse-Checkout + SHA-256 Incremental

ARQUITECTURA ROBUSTA Y MODULAR

Ingeniería de Precisión para la Educación IA

Independencia, Soberanía y Cero Alucinaciones de API.